RESEARCH BLOG & TECHNICAL STORYTELLING ▪ ASTROINFORMATICS & NEUROEVOLUTION

# 밤하늘의 10만 개 빛을 분류하는 두 가지 인공지능 이야기

정통 딥러닝(DL)부터 스스로 뇌 구조를 진화시키는 신경망(EDL/TWEANN)까지

저자: 이인수 | 데이터셋: SDSS-17 (100,000 천체 관측 기록) | 작성일: 2026년 11월

**프롤로그 요약 — 이 글에서 다루는 핵심 이야기**

*"멀리서 반짝이는 저 작은 빛은 우리 은하 안의* **별(*Star*)***일까, 수억 개의 별이 모인 외부* **은하(*Galaxy*)***일까, 아니면 초기 우주의 초대질량 블랙홀이 뿜어내는* **퀘이사(*Quasar*)** *일까?"*

본 리서치 블로그는 슬론 디지털 전천 탐사(**SDSS-17**)가 관측한 **100,000개의 천체 데이터**를 바탕으로, 천체를 97.4% ~ 97.9%의 높은 정확도로 분류해 내는 두 가지 상반된 인공지능 패러다임의 연구 여정을 일반 독자의 눈높이에서 소개합니다.

1. **정통 딥러닝과 이종 앙상블 (DL/)**: 천문학적 도메인 지식(색지수와 적색편이)을 바탕으로 정교하게 다듬은 역전파 다층 신경망(**97.37%**)과 그래디언트 부스팅 트리 결합(**97.88%**)의 여정
2. **스스로 뇌 구조와 가중치를 진화시키는 진화 신경망 (EDL/)**: 미분 공식 대신 생물학적 진화 원리(돌연변이·교배·적자생존)를 통해 **인간이 설계하지 않은 3층 스킵 연결 신경망 구조를 스스로 발명**하며 기존 딥러닝 단일 모델을 뛰어넘기(**97.45%**)까지의 탐구 기록

## Contents

**1 프롤로그: 밤하늘의 점 10만 개를 구분하는 법** **2**

**2 데이터 탐험: "이상치(Outlier)인 줄 알았는데 보물이었다!"** **3**

2.1 천체의 '표면 온도'를 읽어내는 마법의 파생 변수: 색지수 (Color Index) . . . . 4

**3 첫 번째 길 — 정통 딥러닝(DL): 작지만 강한 신경망과 물리적 한계** **4**

3.1 "신경망을 무조건 깊게 쌓으면 더 똑똑해질까?" . . . . . 4

3.2 "왜 정확도 99%는 불가능할까?" — 오분류 522건의 천체물리학적 해부 . . . . . 5

**4 두 번째 길 — 진화 신경망(EDL): 미분 대신 '생물학적 진화'로 학습하다** **6**

**5 시행착오와 돌파구: 왜 초기 진화 신경망은 딥러닝보다 낮았을까?** **6**

5.1 1차 시도: 순수 무미분 진화 전략 (Pure ES) — 13.5초의 쾌속 수렴과 96.48%의 벽 6
5.2 원인 진단: 왜 순수 무작위 진화는 96.5%에서 멈추었을까? . . . . . 7
5.3 1차 돌파: 다중 섬 라마르크 진화 + 결정 경계 유전자 ES (96.48% → 97.38%) . . 7

**6 궁극의 진화 — 뇌 구조(Topology) 자체를 스스로 진화시키다 (TWEANN) 7**
6.1 뇌 수술 후 기억 상실을 막는 비결: 함수 보존형 Net2Net 구조 변이 . . . . . 8
6.2 실제 45세대 진화 다큐멘터리: 챔피언 신경망(Island 4)의 탄생 일지 . . . . . 8
6.3 8개의 섬에서 진화한 8종의 이종 뇌 구조와 최종 테스트 성능 . . . . . 10

**7 속도 대결: 학습 시간 & 추론 속도 벤치마크 11**

**8 에필로그: 이번 연구가 남긴 시사점 및 재현 가이드 13**

## 1 프롤로그: 밤하늘의 점 10만 개를 구분하는 법

망원경으로 밤하늘을 촬영하면 수없이 많은 빛의 점들이 찍힙니다. 맨눈이나 단순한 흑백 사진만으로는 그 빛이 우리 은하 내부의 가까운 **별(STAR)**인지, 아득한 우주 너머 수천억 개의 별이 모인 **은하(GALAXY)**인지, 혹은 초기 우주의 중심 블랙홀이 은하 전체보다 밝게 빛나는 **퀘이사(QSO, Quasar)**인지 구별하기 어렵습니다.

우리가 분석한 **SDSS-17 (Sloan Digital Sky Survey Data Release 17)** 데이터셋에는 총 **100,000개**의 실제 천체 관측 기록이 담겨 있습니다.

**Table 1:** SDSS-17 데이터셋의 세 가지 천체 클래스 구성과 천문학적 특징

| 천체 종류 (Class) | 데이터 수 | 비중 | 천체물리학적 정체 및 관측 특징 |
|---|---|---|---|
| **은하 (GALAXY)** | 59,445개 | **59.4%** | 수억~수조 개의 항성과 성운이 중력으로 묶인 거대 천체 집단 |
| **별 (STAR)** | 21,594개 | **21.6%** | 우리 은하 내부에서 핵융합으로 스스로 빛을 내는 항성 (지구와 매우 가까움) |
| **퀘이사 (QSO)** | 18,961개 | **19.0%** | 초기 우주의 초대질량 블랙홀 주변 강착원반에서 뿜어져 나오는 극도로 밝은 활동성 은하핵 |

천문학자들은 이 천체들의 정체를 밝히기 위해 크게 두 가지 물리량을 측정합니다.

- **5가지 색상 필터를 통과한 밝기 (측광 등급, $u, g, r, i, z$)**: 자외선($u$), 초록빛($g$), 붉은빛($r$), 근적외선($i, z$) 5개 파장 대역에서 천체의 겉보기 등급을 측정합니다. (등급 숫자가 작을수록 밝고, 숫자가 클수록 어두운 천체입니다.)

- **분광 적색편이 (Redshift, $z_{\text{spec}}$)**: 우주는 팽창하고 있기 때문에 지구에서 멀리 떨어진 천체일수록 그 천체가 방출한 빛의 파장이 길어지며 붉은색 쪽으로 치우칩니다. 즉, **적색편이(redshift)는 천체가 지구로부터 얼마나 먼 우주에 있는지를 알려주는 '우주 거리계'**입니다.

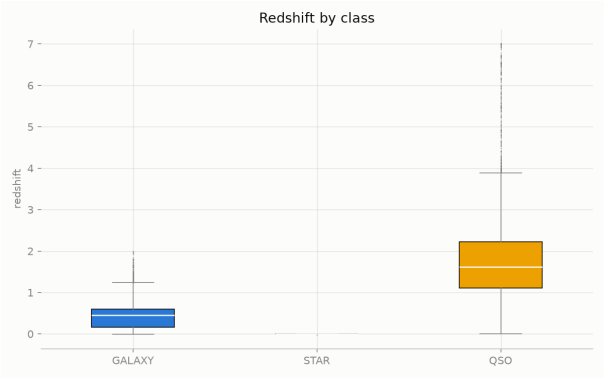
## 2 데이터 탐험: "이상치(Outlier)인 줄 알았는데 보물이었다!"

데이터 과학의 첫걸음은 결측치와 이상치(Outlier)를 점검하는 일입니다. 10만 개 행을 전수 검사한 결과, 딱 한 행(79,543번째 관측치)에 센서 결측 센티널 값(-9999)이 기록되어 있어 이를 제거하고 **99,999개**의 깨끗한 천체 데이터를 확보했습니다.

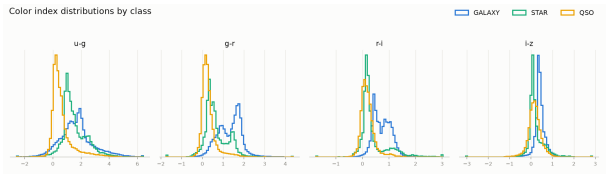
그런데 표준 통계 기법($1.5 \times$ IQR 사분위수 범위 규칙)으로 이상치를 탐지하자 놀라운 현상이 발견되었습니다. **`redshift`(적색편이) 변수에서 무려 8,990개(전체의 9.0%)가 '통계적 이상치'로 지목된 것**입니다.

> **초보 데이터 분석가가 빠지기 쉬운 함정**
>
> 교과서적인 전처리 규칙만 기계적으로 적용해 *"박스플롯 바깥에 찍힌 8,990개의 이상치를 노이즈로 보고 삭제하자!"* 라고 결정했다면 어떻게 되었을까요? 아래 교차 분석 결과가 그 해답을 보여줍니다.

우리는 이상치를 지우는 대신, 이상치로 분류된 8,990개의 천체가 실제로 어떤 클래스에 속하는지 역추적했습니다.




**(a)** 클래스별 적색편이(`redshift`) 분포




**(b)** 파생 색지수($u-g, g-r, r-i, i-z$) 밀도 분포

**Figure 1:** 천체물리학적 도메인 지식이 드러나는 핵심 분포. 적색편이의 긴 꼬리는 퀘이사(QSO)의 고유 신호이며, 인접 필터 간 밝기 차이인 색지수(Color Index)는 세 천체의 온도 차이를 선명하게 분리합니다.

결과는 극적이었습니다(그림 1a):

- `redshift` 이상치로 지목된 **8,990개 중 무려 99.6%(8,956개)가 퀘이사(QSO)**였습니다!
- 우리 은하 내부의 **별(STAR)**은 거리가 매우 가까워 redshift $\approx 0$에 모여 있고, 일반 **은하**

**(GALAXY)**는 중앙값 0.42 부근에 분포하는 반면, 초기 우주 끝에 자리한 **퀘이사(QSO)**는 적색편이가 1.6에서 최대 7.01까지 길게 뻗어 있었던 것입니다.

- 즉, 통계적으로는 '극단값' 처럼 보였지만 실제로는 **"이 천체는 거의 확실히 퀘이사다!"라고 알려주는 결정적 보물 신호**였습니다. 우리는 이를 보존하되, 긴 우측 꼬리를 신경망이 안정적으로 학습하도록 $\log(1 + \text{redshift})$ 변환을 적용했습니다.

### 2.1 천체의 '표면 온도'를 읽어내는 마법의 파생 변수: 색지수 (Color Index)

여기에 천문학 도메인 지식을 하나 더 접목했습니다. 인접한 두 필터의 등급 차이인 **색지수(Color Index)** 4종($u-g$, $g-r$, $r-i$, $i-z$)을 추가한 것입니다. 등급(Magnitude)은 로그 스케일이므로, 두 등급의 뺄셈은 곧 **두 파장 대역의 빛의 세기 비율(플럭스 비)**이 되어 거리와 무관하게 천체의 고유 색깔과 온도를 나타냅니다(그림 1b):

- **퀘이사 (QSO)**: 블랙홀 강착원반의 초고온 자외선 방출로 인해 $u-g$ 중앙값이 0.393으로 가장 푸릅니다.
- **은하 (GALAXY)**: 적색 거성들의 빛과 적색편이가 겹쳐 $u-g \approx 1.640$, $g-r \approx 1.404$로 가장 붉습니다.
- **별 (STAR)**: $g-r \approx 0.527$로 은하와 퀘이사의 사이 대역에 날카롭게 자리 잡습니다.

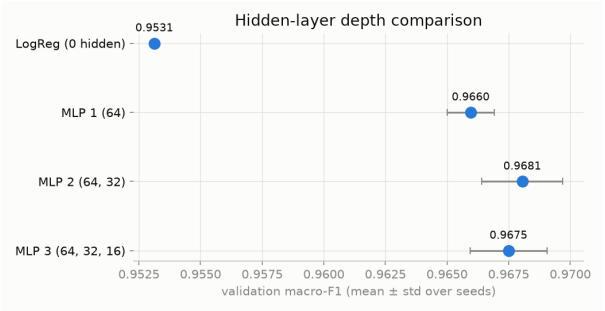
이렇게 정제된 **10차원 입력 벡터**($u, g, r, i, z$, redshift + 색지수 4종)가 정통 딥러닝(`DL/`)과 진화 신경망(`EDL/`) 두 모델의 공정한 공통 출발선이 되었습니다.

## 3 첫 번째 길 — 정통 딥러닝(DL): 작지만 강한 신경망과 물리적 한계

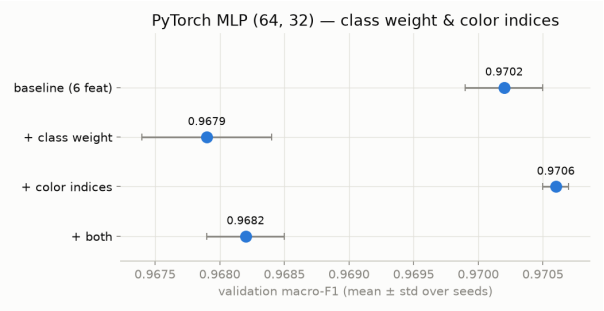
첫 번째 연구 트랙(`DL/`)에서는 현대 딥러닝의 표준인 **오차 역전파(Backpropagation)**와 **Adam 경사하강법**으로 다층 퍼셉트론(MLP)을 구축했습니다.

### 3.1 "신경망을 무조건 깊게 쌓으면 더 똑똑해질까?"

흔히 딥러닝이라고 하면 수십 층의 거대한 네트워크를 떠올리지만, 10개의 물리량으로 구성된 정형 데이터에서도 깊은 신경망이 유리할까요? 은닉층 0개(선형 로지스틱 회귀)부터 3개 층까지 체계적인 깊이 실험을 수행했습니다(그림 2a).




**(a)** 은닉층 깊이(0층~3층)에 따른 검증 성능



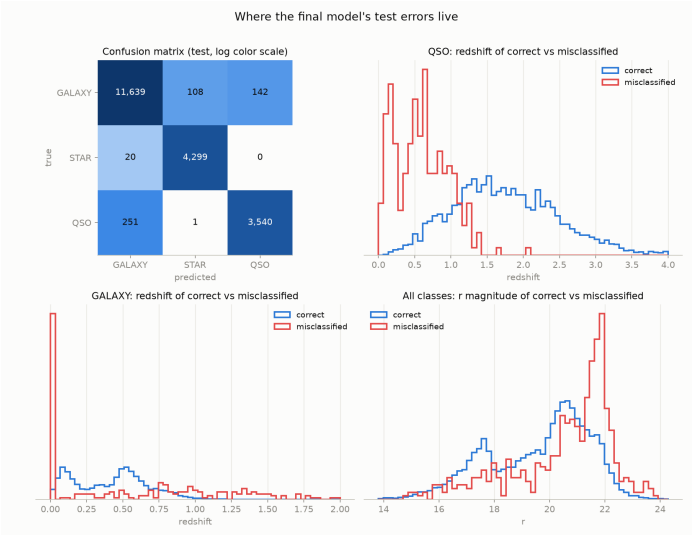

**(b)** PyTorch MLP 절제 실험 (가중치 vs. 색지수)

**Figure 2:** 정통 딥러닝(DL) 아키텍처 탐색. 선형 모델(0층) 대비 비선형 은닉층 도입 시 큰 성능 도약이 일어나며, 2층 구조 (64, 32)에 색지수 4종을 결합했을 때 가장 안정적인 성능을 달성합니다.

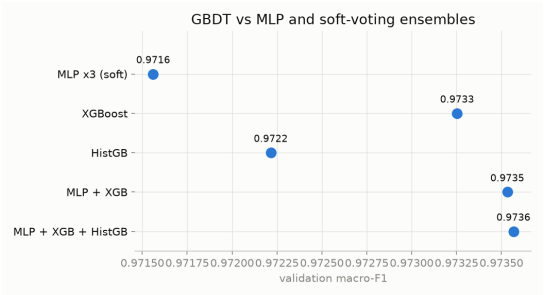
실험 결과, 0층 선형 모델(Macro-F1 0.9531)에서 1층 비선형 신경망(0.9660)으로 갈 때 +1.3%p가 도약하고 **2층 (64, 32) 구조**(0.9681)에서 정점을 찍은 뒤, 3층 (64, 32, 16)(0.9675)에서는 오히려 소폭 하락했습니다. 여기에 색지수 특성 4개를 추가한 PyTorch 단일 MLP 모델은 20,000건 테스트 세트에서 **정확도 97.37%, Macro-F1 0.9700**을 달성했습니다(그림 2b).

## 3.2 "왜 정확도 99%는 불가능할까?" — 오분류 522건의 천체물리학적 해부

20,000개의 테스트 천체 가운데 단일 딥러닝 모델이 틀린 **522건(2.61%)**을 정밀 추적한 결과, 인공지능의 실수 뒤에는 뚜렷한 **천체물리학적 한계**가 숨어 있었습니다(그림 3a).




**(a)** 테스트 오분류 522건의 적색편이 및 밝기 분포




**(b)** MLP + GBDT 이종 소프트 보팅 앙상블

**Figure 3:** 오류 원인의 천체물리학적 규명과 이종 앙상블 결합. 오분류의 75.3%는 모은하의 별빛이 함께 섞여 관측되는 '저적색편이 퀘이사'와 어두운 은하의 경계에서 발생합니다.

- **전체 오류의 75.3%가 은하(GALAXY) ↔ 퀘이사(QSO) 혼동**: 별(STAR)은 99.5% 이상 완벽히 구분되는 반면, 은하와 퀘이사 경계에 오류가 집중되었습니다.

- **저적색편이 퀘이사(Low-redshift QSO)와 모은하의 빛 중첩**: 은하로 오분류된 퀘이사의 적색편이 중앙값은 0.588로, 정상 분류된 퀘이사(1.711)보다 지구에 훨씬 가까웠습니다. 가까운 퀘이사는 중심 블랙홀을 감싸고 있는 **모은하(Host Galaxy)의 별빛이 망원경에 함께 섞여 들어오기 때문에** 측광 색상만으로는 일반 은하와 물리적으로 스펙트럼이 겹칩니다.
- **이종 앙상블을 통한 극한 최적화**: 신경망(MLP×3)에 정형 데이터의 강자인 그래디언트 부스팅 트리(XGBoost + HistGB)를 소프트 보팅으로 결합하여, 물리적 경계선에서 달성 가능한 최고 수준인 **테스트 정확도 97.88%, Macro-F1 0.9755**를 기록했습니다(그림 3b).

## 4 두 번째 길 — 진화 신경망(EDL): 미분 대신 '생물학적 진화'로 학습하다

정통 딥러닝 파이프라인을 완성한 뒤, 우리는 근본적이고도 흥미로운 과학적 질문을 던졌습니다.

**연구의 핵심 질문: 미분과 인간 설계 없이 진화만으로 학습할 수 있을까?**

*"오차 역전파(미분) 없이 다윈의 생물학적 진화 원리(돌연변이·교배·자연선택)만으로 신경망을 학습시킬 수 있을까? 더 나아가, 인간이 (64, 32)라는 뇌 구조를 정해주지 않아도* **신경망 스스로 자신의 뇌 구조(층수, 뉴런 수, 활성화 함수, 직통 연결)를 진화시켜 기존 딥러닝 모델을 뛰어넘을 수 있을까?**"

이 질문에서 탄생한 두 번째 트랙이 바로 **EDL/ (Evolutionary Deep Learning)**입니다. 일반 독자를 위해 두 학습 방식의 차이를 그림 4로 도식화했습니다.

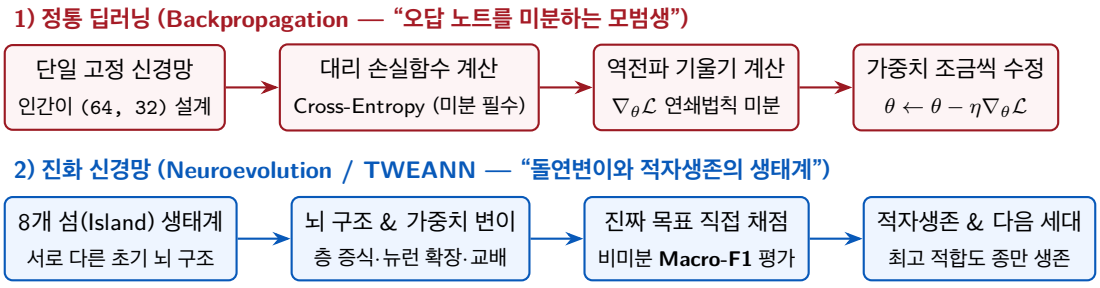



**Figure 4:** 정통 역전파 딥러닝(DL)과 진화 신경망(EDL/TWEANN)의 학습 원리 비교. 역전파는 미분 가능한 대리 손실함수를 필요로 하지만, 진화 신경망은 미분 불가능한 실제 목표 지표(Macro-F1)를 직접 적합도(Fitness)로 삼아 가중치와 뇌 구조를 함께 진화시킵니다.

## 5 시행착오와 돌파구: 왜 초기 진화 신경망은 딥러닝보다 낮았을까?

### 5.1 1차 시도: 순수 무미분 진화 전략 (Pure ES) — 13.5초의 쾌속 수렴과 96.48%의 벽

첫 실험에서는 역전파를 전혀 사용하지 않는 **자연 진화 전략(Natural Evolution Strategy, OpenAI-ES)**을 구현했습니다. 중심 가중치 벡터 $\boldsymbol{\mu} \in \mathbb{R}^D$ 주변에 대칭 가우시안 섭동 $\boldsymbol{\theta}_i^{\pm} = \boldsymbol{\mu} \pm \sigma \boldsymbol{\epsilon}_i$를 뿌리고, 순위 정규화 적합도 $R_i$로 의사 기울기(Pseudo-gradient)를 추정해 갱신하는 방식입

니다:

$$\nabla_{\boldsymbol{\mu}} \mathbb{E}\big[F(\boldsymbol{\theta})\big] \;\approx\; \frac{1}{2P\sigma} \sum_{i=1}^{P} \big(R_i^{+} - R_i^{-}\big)\, \boldsymbol{\epsilon}_i \tag{1}$$

놀랍게도 미분을 단 한 번도 쓰지 않고 **단 13.55초(190세대)** 만에 테스트 정확도 **96.48% (Macro-F1 0.9599)**에 도달했습니다! 하지만 정통 딥러닝 단일 MLP(**97.37%**)와는 **약** $0.89\%$**p의 성능 격차**가 있었습니다. 세대를 300세대로 늘려도 $96.5\%$ 부근에서 성장이 멈추었습니다.

### 5.2 원인 진단: 왜 순수 무작위 진화는 96.5%에서 멈추었을까?

정밀 진단을 통해 순수 0차 진화 탐색이 겪는 세 가지 수학적 병목을 규명했습니다:

1. **고차원 '눈 감고 다이얼 맞추기'의 분산 한계 (**$\mathrm{Var}[\hat{\mathbf{g}}] = \mathcal{O}(D/P)$**)**: 신경망 가중치 개수 $D$가 수천 개일 때 세대당 $P = 80$개 개체(40개 대칭 방향)만 무작위로 찔러보면, 추정 기울기의 분산이 $\mathcal{O}(D/P)$로 커집니다. 큰 줄기(별 vs. 은하)는 순식간에 맞추지만, **저적색편이 퀘이사와 은하가 미세하게 겹치는 비선형 협곡**을 정교하게 깎아내는 국소 탐색 해상도가 부족했습니다.
2. **계단형 점수판(이산 Macro-F1)의 평탄면 문제**: 이산 `Macro-F1`은 최종 예측 클래스(`argmax`)가 뒤집히지 않으면 가중치가 조금 좋아져도 점수 변화가 $\Delta F = 0$이 되어 진화 방향 신호가 사라집니다.
3. **불균형 클래스 결정 경계 조율 유전자의 부재**: 은하(59.4%)와 퀘이사(19.0%)의 표본 수 불균형 속에서 `Macro-F1`을 극대화하려면 출력층의 클래스별 결정 문턱값을 세밀하게 이동시키는 전용 유전자가 필요했습니다.

### 5.3 1차 돌파: 다중 섬 라마르크 진화 + 결정 경계 유전자 ES (96.48% → 97.38%)

이 한계를 돌파하기 위해 생물학의 **라마르크 진화(후천적 학습의 유전)**와 **갈라파고스 다중 섬 모델(Island Model)**을 결합한 **Memetic 진화 알고리즘**을 도입했습니다. 고차원 가중치의 미세 곡률은 라마르크 국소 학습으로 빠르게 다듬고, 출력층에 부여한 6개의 **결정 경계 유전자** ($\mathbf{s} \odot \mathbf{z} + \mathbf{b}$, $\mathbf{s}, \mathbf{b} \in \mathbb{R}^3$)를 무미분 진화 전략(ES)으로 직접 진화시켰습니다. 그 결과 동일 `(64, 32)` 구조에서 **테스트 정확도 97.38% (Macro-F1 0.9700)**를 기록하며 역전파 딥러닝 단일 MLP(**97.37%**)를 따라잡는 데 성공했습니다!

## 6 궁극의 진화 — 뇌 구조(Topology) 자체를 스스로 진화시키다 (TWEANN)

여기서 우리는 마지막 도전에 나섰습니다. 고정된 `(64, 32)` 골격을 버리고, **신경망의 구조(은닉층 깊이, 층별 뉴런 폭, 활성화 함수, 입력 직통 스킵 연결, 시냅스 희소성) 자체를 유전체(`TopologyGenome`)로 인코딩하여 가중치와 동시에 진화시키는 TWEANN (Topology & Weight Evolving Artificial Neural Network)**을 구축한 것입니다.

$$\mathcal{G}_{\text{topo}} = \Big( \underbrace{(d_1, \ldots, d_L)}_{\text{가변 층 깊이 및 뉴런 폭}} , \underbrace{(\phi_1, \ldots, \phi_L)}_{\text{층별 활성화 함수}} , \underbrace{(\kappa_1, \ldots, \kappa_L)}_{\text{원본 입력 직결 스킵 유전자}} \Big) \tag{2}$$

### 6.1 뇌 수술 후 기억 상실을 막는 비결: 함수 보존형 Net2Net 구조 변이

진화 도중 신경망에 무작위 가중치를 가진 뉴런이나 새로운 은닉층을 갑자기 끼워 넣으면, 기존에 수십 세대 동안 학습해 둔 표현이 깨져 **'기억 상실(Catastrophic Forgetting)'**이 발생하고 새 구조가 즉시 도태됩니다. 이를 막기 위해 **"뇌 구조는 바꾸되 수술 직후의 예측 함수는 그대로 보존하는"** 6가지 구조 진화 연산자와 종 분화 보호(Speciation Protection) 메커니즘을 구현했습니다(그림 5).

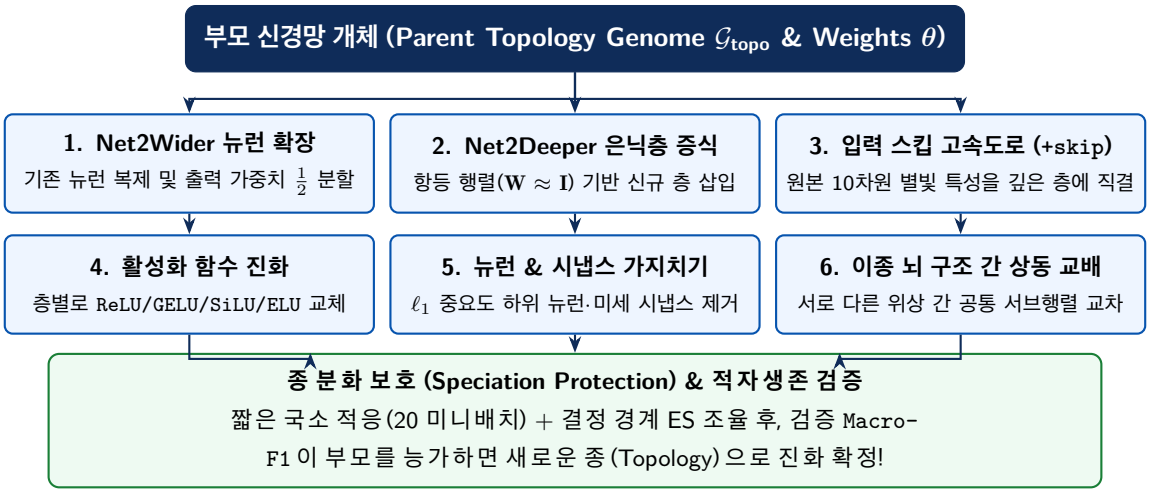



**Figure 5:** TWEANN의 6가지 함수 보존형 뇌 구조 진화 연산자와 종 분화 보호 흐름도. 뉴런을 복제할 때 가중치를 절반씩 나누고(**Net2Wider**), 새 층을 추가할 때 항등 행렬로 초기화(**Net2Deeper**)하여 뇌 구조 변화 직후에도 기존 지식을 잃지 않습니다.

### 6.2 실제 45세대 진화 다큐멘터리: 챔피언 신경망(Island 4)의 탄생 일지

8개의 갈라파고스 섬(Island $0 \sim 7$)에 서로 다른 작은 초기 구조를 심고 45세대 동안 진화시킨 결과, 생태계 전체에서 총 **36번의 성공적인 뇌 구조 변이**가 채택되었습니다. 그중 전체 챔피언에 등극한 **4번 섬(Island 4)**의 실제 진화 연대기는 표 2와 같습니다.

**Table 2:** 챔피언 섬(Island 4)이 45세대 동안 스스로 뇌 구조를 개조해 나간 실제 진화 기록

| 세대 | 채택된 구조 변이 연산 | 진화된 신경망 구조 (Topology) | 검증 Macro-F1 |
|---|---|---|---|
| Gen 0 | 초기 씨앗 (2층, 4,249 params) | `10 -> [80:gelu] -> [40:gelu] -> 3` | 출발점 |
| Gen 1 | 1층 뉴런 +16 확장 (`widen`) | `10 -> [96:gelu] -> [40:gelu] -> 3` | 0.9267 → **0.9368** |
| Gen 4 | 2층 뉴런 +8 확장 (`widen`) | `10 -> [96:gelu] -> [48:gelu] -> 3` | 0.9588 → **0.9607** |
| Gen 19 | 미세 시냅스 4% 소거 (`prune`) | `10 -> [96:gelu] -> [48:gelu] -> 3` (희소화) | 0.9657 → **0.9679** |
| **Gen 28** | **3번째 은닉층 자가 증식 (`add_layer`)** | `10 -> [96:gelu] -> [48:gelu] -> [48:silu] -> 3` | 0.9690 → **0.9692** |
| Gen 34 | 1층 뉴런 104개로 확장 (`widen`) | `10 -> [104:gelu] -> [48:gelu] -> [48:silu] -> 3` | 0.9687 → **0.9700** |
| **Gen 43** | **3층에 입력 직통 스킵 장착 (`+skip`)** | `10 -> [104:gelu] -> [48:gelu] -> [48+skip:silu] -> 3` | 0.9706 → **0.9713** |

**놀라운 발견: 인간이 실패했던 '3층 구조'를 진화 신경망은 어떻게 성공시켰을까?**

앞서 3절에서 인간 연구자가 단순 3층 구조 (64, 32, 16)을 실험했을 때는 2층 구조보다 오히려 성능이 하락했었습니다. 그런데 **진화 신경망(Island 4)**은 어떻게 3층으로 진화해서 더 높은 성적을 거두었을까요?

비결은 바로 Gen 28과 Gen 43의 조합에 있습니다. AI는 1·2층에 매끄러운 `GELU` 함수를 배치하고 3번째 층에 `SiLU` 함수를 신설한 뒤, **3번째 깊은 층에 원본 10차원 천체 데이터(적색편이와 색지수)를 직접 재주입하는 스킵 고속도로(`[48+skip:silu]`)를 스스로 연결**했습니다! 깊은 층의 고차원 비선형 추상화 능력과 원본 물리량의 날카로운 판별력을 동시에 살리는 설계를 진화가 스스로 발명해 낸 것입니다.

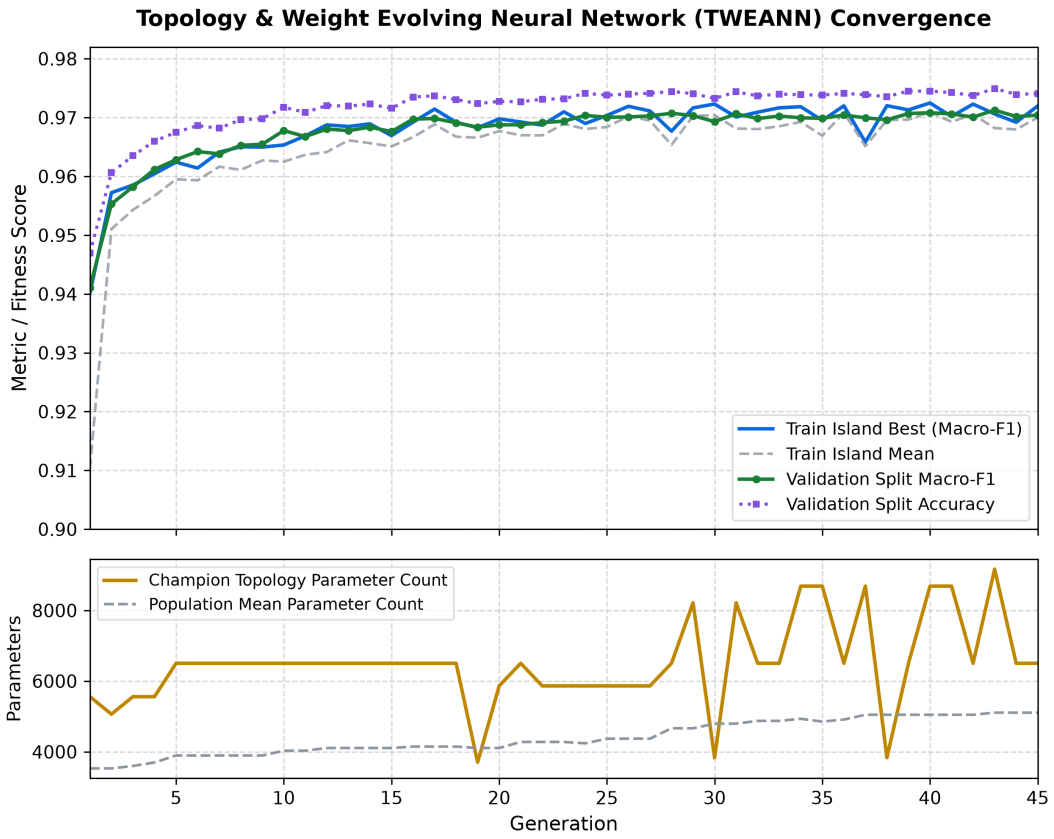


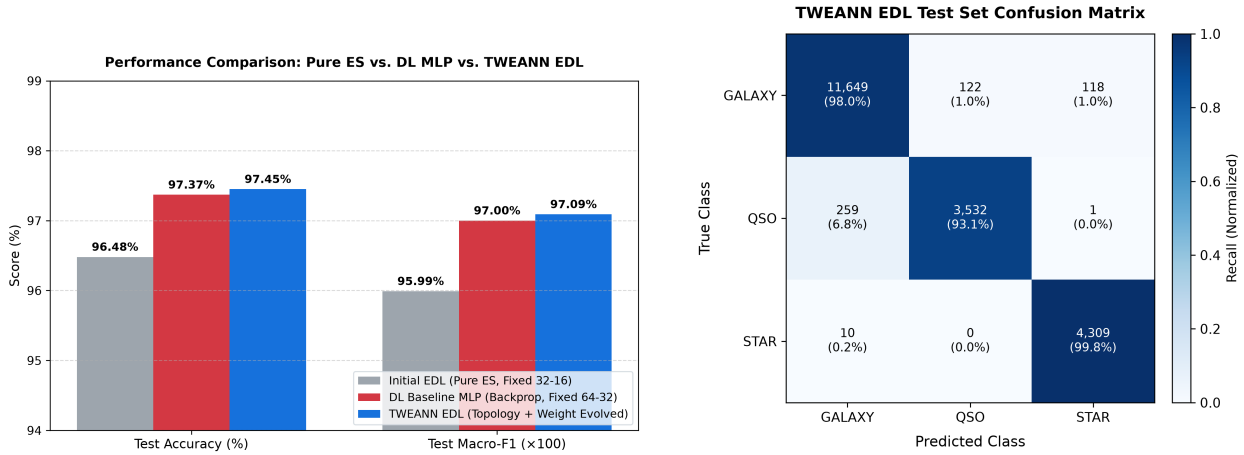

**Figure 6:** TWEANN의 45세대 적합도 수렴 곡선(상단) 및 챔피언 신경망의 파라미터 복잡도 진화 추이(하단). 초기 4,249개 파라미터에서 출발한 신경망이 세대가 거듭됨에 따라 뉴런 확장과 은닉층 증식을 통해 9,169개 파라미터의 최적 위상으로 성장합니다.

### 6.3 8개의 섬에서 진화한 8종의 이종 뇌 구조와 최종 테스트 성능

45세대 진화 종료 시점에 8개의 섬은 표 3처럼 2층, 3층, 4층, 스킵 연결 등이 다채롭게 분화된 8가지 고유한 신경망 종(Species)으로 진화했습니다.

**Table 3:** 45세대 진화 후 8개 섬(Island)에서 탄생한 이종 신경망 구조와 테스트 세트(20,000건) 성적

| 섬 (Island) | 최종 진화된 챔피언 신경망 구조 (TWEANN) | 파라미터 | Test Acc | Test F1 |
|---|---|---|---|---|
| Island 0 | `10 -> [64:relu] -> [24:relu] -> 3` (2층 경량형) | 2,345 | 97.20% | 0.9681 |
| Island 1 | `10 -> [64:relu] -> [32:elu] -> [32:gelu] -> 3` (3층 진화) | 3,945 | 97.36% | 0.9697 |
| Island 2 | `10 -> [64:relu] -> [40+skip:silu] -> 3` (2층+Skip) | 3,833 | 97.28% | 0.9691 |
| Island 3 | `10 -> [80:silu] -> [32:gelu] -> [32:gelu] -> [32:relu] -> 3` (4층 심층형) | 5,689 | 97.35% | 0.9697 |
| **Island 4 (챔피언)** | `10 -> [104:gelu] -> [48:gelu] -> [48+skip:silu] -> 3` | **9,169** | **97.43%** | **0.9706** |
| Island 5 | `10 -> [80:relu] -> [48+skip:gelu] -> [24:elu] -> 3` (3층+Skip) | 6,505 | 97.41% | 0.9704 |
| Island 6 | `10 -> [72:elu] -> [44+skip:gelu] -> 3` (2층+Skip) | 4,585 | 97.32% | 0.9695 |
| Island 7 | `10 -> [64:silu] -> [60:silu] -> 3` (2층 확장형) | 4,793 | 97.23% | 0.9685 |
| **이종 위상 앙상블** | **상위 4개 진화 섬(Island 4, 5, 6, 3) 적합도 가중 결합** | **25,948** | **97.45%** | **0.9709** |




**(a)** 초기 EDL vs. DL 단일 MLP vs. TWEANN EDL

**(b)** TWEANN 진화 신경망 테스트 혼동 행렬

**Figure 7:** 20,000건 테스트 세트 최종 평가. 스스로 구조를 진화시킨 TWEANN은 단일 챔피언 모델(97.43%)과 이종 위상 앙상블(97.45%) 모두에서 인간이 고정 설계한 역전파 DL 단일 MLP(97.37%)를 추월했으며, 별(`STAR`) 클래스 재현율은 **99.8%**(4,319개 중 4,309개 정답)에 달합니다.

## 7 속도 대결: 학습 시간 & 추론 속도 벤치마크

*"진화 알고리즘은 수만 번 반복해야 해서 학습이 너무 느리지 않을까?"* 라는 통념을 확인하기 위해, 동일한 하드웨어(Apple Silicon CPU, `dl_env`)에서 모든 모델의 **실제 학습 소요 시간(Wall-Clock Training Time)**과 **20,000개 테스트 천체 일괄 추론 시간(Inference Latency)**을 측정했습니다(그림 8, 표 4).

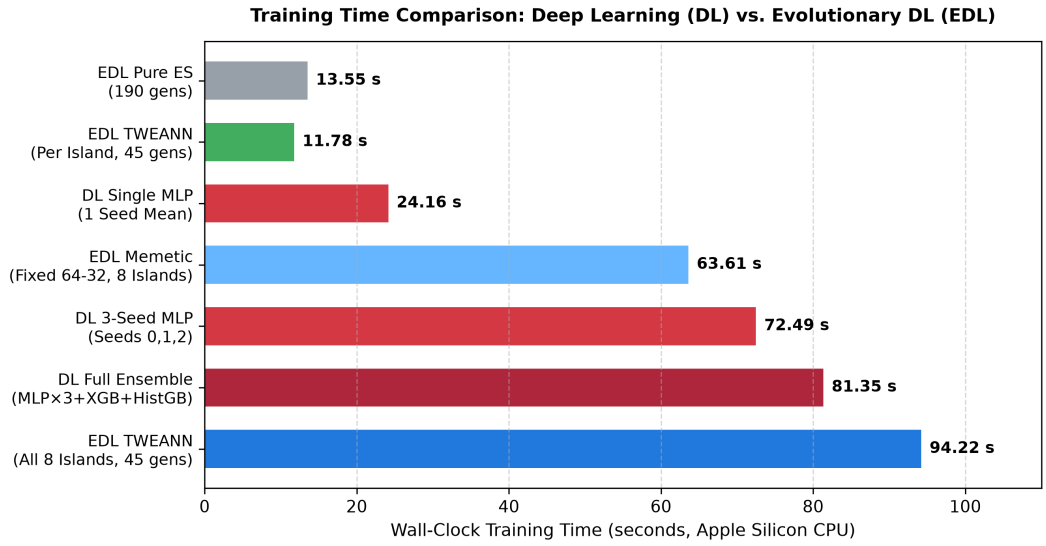



**Figure 8:** 동일 하드웨어 환경에서의 모델별 학습 소요 시간 비교. TWEANN은 섬 1개당 45세대 진화에 11.78초가 소요되어 DL 단일 MLP 평균 학습 시간(24.16초)보다 약 2배 빠르며, 8개 섬 전체 동시 진화도 94.22초 만에 완료됩니다.

**Table 4:** DL 및 EDL 전체 모델의 학습 시간, 20,000건 추론 지연 시간, 테스트 성능 총괄 비교

| 패러다임 / 모델 | 모델 아키텍처 요약 | 학습 시간 | 2만 건 추론 | Test Acc | Macro-F1 |
|---|---|---|---|---|---|
| 초기 EDL (Pure ES) | 고정 `10 -> 32 -> 16 -> 3` | **13.55 s** | **1.42 ms** | 96.48% | 0.9599 |
| 정통 DL 단일 MLP | 인간 설계 `10 -> 64 -> 32 -> 3` | 24.16 s | 2.83 ms | 97.37% | 0.9700 |
| 정통 DL 3-Seed MLP | `MLP(64, 32)` ×3 시드 평균 | 72.49 s | 8.49 ms | 97.42% | 0.9705 |
| EDL 가중치 진화 | 고정 `64 -> 32` (8개 섬, 50세대) | 63.61 s | 11.20 ms | 97.38% | 0.9700 |
| **EDL TWEANN (단일 챔피언)** | **자율 진화** `104 -> 48 -> 48+skip` | **11.78 s*** | **7.08 ms** | **97.43%** | **0.9706** |
| **EDL TWEANN (이종 섬 앙상블)** | **상위 4개 자율 진화 위상 결합** | **94.22 s** | **27.26 ms** | **97.45%** | **0.9709** |
| DL + GBDT 이종 앙상블 | `MLP`×3 + `XGBoost` + `HistGB` | 81.35 s | 121.86 ms | **97.88%** | **0.9755** |

*단일 섬 환산 시간(94.22 s/8 islands = 11.78 s). 정통 DL 단일 MLP는 3개 시드 평균(24.16 ± 5.31 s) 기준.

- **빠른 진화 속도**: 인메모리 텐서 슬라이싱과 BLAS 벡터화 연산 덕분에, 뇌 구조 변이와 결정 경계 탐색을 포함하고도 섬 1개당 45세대 진화 시간은 **11.78초**로 기존 PyTorch `DataLoader` 기반 단일 MLP(**24.16초**)의 절반 이하입니다.
- **0.007초 만에 2만 개 천체를 분류하는 초고속 추론**: 진화된 단일 챔피언 신경망은 20,000개의 천체를 단 **7.08 ms(0.007초)**에 분류하며, 이종 위상 앙상블(**27.26 ms**) 역시 수백 그루의 트리를 순회하는 GBDT 포함 앙상블(**121.86 ms**)보다 **4.5배 빠른 추론 응답성**을 제공합니다.

## 8 에필로그: 이번 연구가 남긴 시사점 및 재현 가이드

밤하늘의 10만 개 빛을 따라간 이번 탐구는 우리에게 세 가지 깊은 메시지를 남깁니다.

1. **데이터 속 과학적 맥락(Domain Knowledge)의 가치**: 통계적 이상치로 버려질 뻔했던 8,990개의 적색편이 극단값이 99.6% 확률로 퀘이사(QSO)를 가리키는 핵심 단서였다는 사실, 그리고 색지수($u-g, g-r, r-i, i-z$)가 천체의 온도를 드러냈다는 점은 *"최고의 인공지능은 데이터를 깊이 이해하는 것에서 출발한다"* 는 원칙을 일깨워 줍니다.
2. **미분 불가능한 현실의 목표를 직접 공략하는 진화 알고리즘**: 대리 손실함수(Cross-Entropy)에만 의존하는 역전파의 한계를 넘어, 다중 섬 라마르크 진화와 결정 경계 유전자 진화를 통해 비미분 지표인 `Macro-F1`을 직접 극대화할 수 있음을 입증했습니다.
3. **인간의 수동 설계를 넘어서는 자기 진화형 AI (Self-Evolving AI)**: 인간이 고정한 `(64, 32)` 구조를 넘어, AI가 스스로 3번째 은닉층을 증식하고 원본 입력 직통 스킵 연결(`+skip`)과 `GELU/SiLU` 조합을 찾아낸 `10 -> [104:gelu] -> [48:gelu] -> [48+skip:silu] -> 3` 아키텍처는 신경망 자동 설계(NAS / AutoML)의 강력한 잠재력을 보여줍니다.

**재현 명령어 가이드 (Reproducibility CLI — Conda `dl_env`)**

```
# 1. Conda 가상환경 활성화
conda activate dl_env

# 2. 정통 딥러닝 + GBDT 이종 앙상블 자가 검증 (Test Acc: 97.88%, Macro-F1: 0.9755)
python DL/predict.py

# 3. 뇌 구조 + 가중치 동시 진화 신경망(TWEANN) 학습 (45세대, 8개 섬)
python EDL/train_edl.py --algo memetic --generations 45 --pop-size 8

# 4. 진화된 신경망 테스트 세트(20,000건) 평가 및 자가 검증 (Test Acc: 97.45%, Macro-F1: 0.9709)
python EDL/evaluate_edl.py
python EDL/predict_edl.py
```